

基于本地知识库的论文搜索助手系统 — 用户手册

课程: 数据库系统实验 完成日期: 2026年6月

一、系统简介

本系统是一个基于本地知识库的论文搜索助手，支持上传 PDF 和 Word 格式的学术论文，自动将其解析并向量化存储到知识库中。用户可以通过自然语言提问的方式与系统进行对话，系统会基于已上传的论文内容进行智能检索和回答，并在回答末尾显示引用的论文来源，方便溯源和验证。

主要功能包括：用户注册与登录、论文上传与管理、智能问答（支持流式输出）、多会话管理、论文库管理、文献来源溯源。

二、环境要求

在启动系统之前，请确保你的计算机上已安装以下软件和服务：

必需软件：

- **Python 3.10 或更高版本**：用于运行后端服务和算法层。推荐使用 Conda 进行环境管理。
- **Node.js 18 或更高版本**（含 npm）：用于构建和运行前端界面。
- **MySQL 数据库**：用于存储用户信息、聊天记录和论文元数据。确保 MySQL 服务正在运行。
- **Ollama**：用于在本地运行 Qwen 2.5 7B 大语言模型。请确保 Ollama 服务已启动并已拉取 `qwen2.5:7b` 模型。

网络要求：

- 需要访问阿里云 DashScope API（用于文本嵌入和重排序服务），请确保网络可以连通 `dashscope.aliyuncs.com`。
- 需要一个有效的 DashScope API Key。

三、安装与配置

3.1 获取项目文件

项目文件以 Submit 文件夹的形式提交，包含完整的后端（`backend/`）、算法层（`backend_algo/`）和前端（`frontend/`）源代码。

3.2 配置后端环境

打开终端，进入 `backend` 文件夹：

```
cd backend
```

使用 Conda 创建并激活 Python 3.12 环境：

```
conda create -n paper_assistant python=3.12 -y
conda activate paper_assistant
```

安装 Python 依赖：

```
pip install -r requirements.txt
```

数据库配置：打开 `database.py` 文件，确认 MySQL 连接字符串中的用户名、密码和数据库名与你的本地 MySQL 配置一致。默认连接的是 `localhost:3306` 上的 `test` 数据库。

3.3 配置算法层环境

打开新的终端，进入 `backend_algo` 文件夹：

```
cd backend_algo
```

使用同一个 Conda 环境（或创建新环境），安装依赖：

```
conda activate paper_assistant
pip install -r requirements.txt
```

API Key 配置：打开 `retrieval_service.py` 和 `embed.py` 文件，将 `DASHSCOPE_API_KEY` 变量替换为你自己的阿里云 DashScope API Key。

LLM 地址配置：打开 `retrieval_service.py` 和 `main.py` 文件，确认 Ollama 服务地址（默认为 `http://localhost:11434/v1`，或根据你的实际部署地址修改）。

3.4 配置前端环境

打开新的终端，进入 `frontend` 文件夹：

```
cd frontend
```

安装 Nodejs 依赖：

```
npm install
```

四、启动系统

系统需要同时运行四个服务。请按照以下顺序，在四个独立的终端窗口中分别启动：

第一步：启动主后端（业务层）

```
cd backend
conda activate paper_assistant
uvicorn main:app --port 8000
```

启动成功后，终端会显示 Uvicorn 运行在 <http://127.0.0.1:8000> 上。

第二步：启动 ChromaDB 向量数据库

```
cd backend_algo
conda activate paper_assistant
chroma run --path ./data_vector_db --host localhost --port 8002
```

第三步：启动算法层

```
cd backend_algo
conda activate paper_assistant
uvicorn main:app --port 8001
```

第四步：启动前端

```
cd frontend
npm run dev
```

启动成功后，终端会显示前端开发服务器地址（通常为 <http://localhost:8080> 或 <http://localhost:5173>）。在浏览器中打开该地址即可访问系统。

提示：如果某些 Python 包安装时遗漏，请根据终端中的报错信息手动 `pip install` 对应的包。

五、功能使用说明

5.1 注册与登录

首次使用系统时，需要先注册一个账号。

1. 在浏览器中打开系统首页，会自动跳转到登录页面。
2. 点击登录表单下方的"注册"按钮，进入注册页面。
3. 填写用户名、密码、名字、姓氏和邮箱，点击注册。
4. 注册成功后自动跳转回登录页面，使用刚才注册的账号登录。
5. 登录成功后，系统会保存你的登录状态，后续刷新页面不会丢失。

说明：只有登录后才能访问聊天、上传论文等功能。如果尝试直接访问聊天页面，系统会自动跳转到登录页。

5.2 上传论文

登录后进入聊天页面，在页面底部的输入区域可以看到文件上传按钮。

1. 点击上传按钮（或使用拖拽方式），选择本地的 PDF 或 Word (.docx) 文件。
2. 系统会自动解析文件内容，提取文本和表格，进行向量化处理后存入知识库。
3. 上传成功后，页面左侧的论文库面板会显示该论文的信息，包括自动提取的标题、文件名和知识块数量。
4. 上传过程可能需要几秒到几十秒不等，取决于文件大小。

批量上传：如果有多篇论文需要上传，可以使用项目附带的 `batch_upload.py` 批量上传工具（详见第七节）。

5.3 智能问答

上传论文后，即可在聊天区域向系统提问。

1. 在底部输入框中输入你的问题，例如“这篇论文的主要贡献是什么？”或“请解释一下文中提到的 XX 方法”。
2. 点击发送按钮（或按回车键）。
3. 系统会基于已上传的论文内容进行检索，并以流式方式逐步输出回答（逐字显示）。
4. 回答的末尾会显示引用的论文来源列表。
5. 你可以在同一个会话中继续追问，系统会保持对话上下文。

说明：AI 的回答基于知识库中的论文内容生成。如果问题与已上传论文无关，系统可能会提示参考资料中没有相关信息。回答的准确性取决于知识库内容的质量和问题的相关度。

5.4 查看引用来源

当 AI 的回答引用了论文内容时，有两种方式查看引用的原始论文：

1. **消息下方引用提示：**AI 回答的下方会显示引用论文的文件名，点击可直接在浏览器中打开论文原文。
2. **右侧引用面板：**页面右侧有一个可折叠的引用来源面板（默认收起状态，显示为一个窄条），点击展开后可以看到完整的引用论文列表，点击论文名可在线预览或下载。

5.5 管理会话

系统支持多会话管理，你可以在不同的话题之间切换而不会丢失之前的对话记录。

新建会话：点击左侧会话列表顶部的“新对话”按钮，即可开始一个新的对话。

切换会话：在左侧会话列表中点击任意会话标题，即可切换到该会话并查看完整的历史消息。会话列表按最近更新时间排序，标题取自第一条消息的前 20 个字符。

删除会话：将鼠标悬停在会话列表中的某个会话上，会出现删除按钮。点击后确认即可删除该会话及其所有消息记录。删除操作不可恢复，请谨慎操作。

说明：每次发送第一条消息时，系统会自动创建一个新会话。所有对话记录都持久化存储在数据库中，刷新页面或关闭浏览器后重新登录仍可找回。

5.6 管理论文库

页面左侧下方的论文库面板展示了所有已上传论文的列表，包括论文标题、文件名、知识块数量和上传时间。

查看论文：论文列表按上传时间倒序排列。如果系统成功提取了论文的元数据标题，将以标题为主显示名，文件名作为次要信息显示在下方。

删除单篇论文：将鼠标悬停在某篇论文上，会出现删除按钮。点击后确认即可删除该论文——系统将同时删除向量数据库中的相关向量和 MySQL 中的论文记录。删除操作不可恢复。


清空全部知识库：在输入区域的底部有一个"清空知识库"按钮，点击后确认将删除所有已上传论文和向量数据。这是一个危险操作，请谨慎使用。

5.7 数学公式渲染

系统支持 LaTeX 数学公式的渲染。当 AI 的回答中包含数学表达式时（如 $E = mc^2$ 或 $\sum_{i=1}^n x_i$ ），会自动渲染为美观的数学公式。

六、界面布局说明

聊天页面采用三栏布局：



- **左侧栏：**上方为会话列表（新建、切换和删除对话），下方为论文库面板（查看和管理已上传的论文）。
- **中央区域：**上方为消息历史展示区（支持 Markdown 和 LaTeX 渲染），下方为输入操作区。
- **右侧栏：**引用来源面板，默认收起以节省空间，点击可展开查看当前回答引用的论文列表。

七、批量上传工具

对于需要一次性上传大量论文的场景，系统提供了 `batch_upload.py` 批量上传脚本。

使用方法

1. 打开 `batch_upload.py` 文件，在文件顶部的配置区域修改以下参数：
 - `BASE_URL`：主后端地址（默认 `http://127.0.0.1:8000`）

- **USERNAME** 和 **PASSWORD**：登录账号和密码
- **PAPERS_DIR**：存放论文的本地文件夹路径

2. 在终端中运行脚本：

```
python batch_upload.py
```

或者使用 Windows 批处理文件，双击 **batch_upload.bat** 即可启动（账号密码已内置于文件中）。

脚本会自动登录获取认证 Token，然后逐个上传指定目录下的所有 PDF 和 DOCX 文件，显示每篇论文的处理进度、知识块数量和提取到的标题，最后汇总成功/失败数量和总耗时。

八、常见问题

Q：启动时提示端口被占用怎么办？

确认 8000、8001、8002 端口没有被其他程序占用。可以使用 **netstat -ano | findstr :8000** 等命令检查，必要时修改代码中的端口配置。

Q：上传论文后，AI 回答"参考资料中没有相关信息"？

这可能是因为你提出的问题与已上传论文的内容不相关，或者上传的论文内容较少、向量化后的匹配度不高。尝试上传更多相关论文，或用更具体的方式提问。

Q：刷新页面后聊天记录还在吗？

是的，从 v1.1 版本开始，所有聊天记录都持久化存储在数据库中。刷新页面后重新登录即可看到之前的所有会话和消息。

Q：删除一篇论文后，相关的 AI 回答还能看到吗？

删除论文只影响知识库中的向量数据，已保存的对话记录和 AI 回答不受影响。但如果你再次就相同问题提问，新的回答将无法引用已删除论文的内容。

Q：注册时提示"用户名已存在"？

该用户名已被其他账号使用，请更换一个新的用户名。

Q：流式输出中断或显示不完整？

可能是网络连接不稳定导致 LLM 服务超时，或 Ollama 服务负载较高。请检查 Ollama 服务状态并重新发送消息。

九、退出系统

使用完毕后，点击页面右上角的**登出按钮**即可安全退出系统。退出会清除浏览器中的登录状态，下次访问时需要重新登录。